

SPEECH RECOGNITION (BRIEFLY)

CHAPTER 15, SECTION 6

Phác thảo

- ◇ Lời nói dưới dạng suy luận xác suất
- ◇ Âm thanh lời nói
- ◇ Phát âm từ
- ◇ Chuỗi từ

Bài phát biểu dưới dạng suy luận xác suất

Không dễ để phá hủy một bãi biển đẹp

Tín hiệu giọng nói ồn ào, thay đổi, mơ hồ

Chuỗi từ **có khả năng nhất**, cho tín hiệu giọng nói là gì?

Tức là chọn *Words* để tối đa hóa $P(\textit{Words}|\textit{signal})$

Sử dụng quy tắc Bayes:

$$P(\textit{Words}|\textit{signal}) = \alpha P(\textit{signal}|\textit{Words})P(\textit{Words})$$

Tức là phân rã thành mô hình âm thanh + mô hình ngôn ngữ

Words là chuỗi trạng thái ẩn, *signal* là chuỗi quan sát

Điện thoại

Tất cả lời nói của con người được tạo thành từ 40-50 điện thoại, được xác định bởi

cấu hình của khớp nối (môi, răng, lưỡi, dây thanh âm, luồng không khí)

Hình thành mức độ trung gian của trạng thái ẩn giữa các từ và tín hiệu

⇒ mô hình âm thanh = mô hình phát âm + mô hình điện thoại

ARPAbet được thiết kế cho tiếng Anh Mỹ

[iy]	b <u>ea</u> t	[b]	<u>b</u> et	[p]	<u>p</u> et
[ih]	b <u>i</u> t	[ch]	<u>Ch</u> et	[r]	<u>r</u> at
[ey]	b <u>e</u> t	[d]	<u>d</u> ebt	[s]	<u>s</u> et
[ao]	b <u>ough</u> t	[hh]	<u>h</u> at	[th]	<u>th</u> ick
[ow]	b <u>oa</u> t	[hv]	<u>h</u> igh	[dh]	<u>th</u> at
[er]	B <u>er</u> t	[l]	<u>l</u> et	[w]	<u>w</u> et
[ix]	ros <u>e</u> s	[ng]	si <u>ng</u>	[en]	butt <u>on</u>
:	:	:	:	:	:

Ví dụ: “ trần ” là [s iy | ih ng] / [s iy | ix ng] / [s iy | en]

Âm thanh lời nói

Tín hiệu thô là độ dịch chuyển của micrô theo hàm thời gian; được xử lý thành các khung hình 30ms chồng chéo, mỗi khung được mô tả bởi features

Các tính năng của khung thường là formants — các đỉnh trong phổ công suất

Mẫu điện thoại

Các tính năng của khung trong $P(features|phone)$ được tóm tắt bởi

- một số nguyên trong $[0 \dots 255]$ (sử dụng lượng tử hóa vectơ); hoặc
- các tham số của hỗn hợp Gaussian

Điện thoại ba trạng thái: mỗi điện thoại có ba giai đoạn (Khởi động, Giữa, Kết thúc)

Ví dụ: [t] có Khởi phát im lặng, Mid bùng nổ, Kết thúc rút lên

$\Rightarrow P(features|phone, phase)$

Triphone context: mỗi điện thoại trở thành n^2 điện thoại riêng biệt, tùy thuộc vào điện thoại ở bên trái và bên phải

Ví dụ: [t] trong “star” được viết là [t(s,aa)] (khác với “tar”!)

Triphones hữu ích để xử lý hiệu ứng coarticulation: bộ phát âm có quán tính và không thể chuyển đổi tức thời giữa các vị trí

Ví dụ: [t] trong “thứ tám” có lưỡi chạm vào rang của

Ví dụ về mẫu điện thoại

Mô hình phát âm từ

Mỗi từ được mô tả như một sự phân bố qua các chuỗi điện thoại

Phân phối được biểu diễn dưới dạng mô hình chuyển tiếp HMM

$$P([towmeytow]|\text{"tomato"}) = P([towmaatow]|\text{"tomato"}) = 0.1$$

$$P([tahmeytow]|\text{"tomato"}) = P([tahmaatow]|\text{"tomato"}) = 0.4$$

Cấu trúc được tạo thủ công, xác suất chuyển tiếp được học từ dữ liệu

Từ riêng biệt

Khả năng sửa lỗi kiểu điện thoại + kiểu từ $P(e_{1:t}|word)$ cho từ cô lập

$$P(word|e_{1:t}) = \alpha P(e_{1:t}|word)P(word)$$

Xác suất trước $P(word)$ thu được đơn giản bằng cách đếm tần số từ

$P(e_{1:t}|word)$ có thể được tính toán đệ quy: xác định

$$\ell_{1:t} = \mathbf{P}(\mathbf{X}_t, \mathbf{e}_{1:t})$$

và sử dụng bản cập nhật đệ quy

$$\ell_{1:t+1} = \text{FORWARD}(\ell_{1:t}, \mathbf{e}_{t+1})$$

và sau đó $P(e_{1:t}|word) = \sum_{\mathbf{x}_t} \ell_{1:t}(\mathbf{x}_t)$

Hệ thống đọc chính tả từng từ được đào tạo đạt độ chính xác 95–99%

Nói liên tục

Không chỉ là một chuỗi các vấn đề nhận dạng từ đơn lẻ!

- Các từ liền kề có mối tương quan cao
- Chuỗi các từ có khả năng nhất $\neq$ Chuỗi các từ có khả năng nhất
- Phân đoạn: có rất ít khoảng trống trong lời nói
- Kết hợp từ ngữ—ví dụ: “điều tiếp theo”

Hệ thống giọng nói liên tục quản lý độ chính xác 60–80% vào một ngày đẹp trời

Mô hình ngôn ngữ

Xác suất trước của một chuỗi từ được đưa ra theo quy tắc dây chuyền:

$$P(w_1 \cdots w_n) = \prod_{i=1}^n P(w_i | w_1 \cdots w_{i-1})$$

Mô hình Bigram :

$$P(w_i | w_1 \cdots w_{i-1}) \approx P(w_i | w_{i-1})$$

Huấn luyện bằng cách đếm tất cả các cặp từ trong kho van bản lớn

Các mô hình phức tạp hơn (bát quái, ngữ pháp, v.v.) sẽ giúp ích được đôi chút

HMM kết hợp

Các trạng thái của kiểu ngôn ngữ+từ+điện thoại kết hợp được gán nhãn bởi từ chúng ta đang ở + số điện thoại trong từ đó + trạng thái điện thoại trong số điện thoại đó

Thuật toán Viterbi tìm chuỗi **trạng thái điện thoại** có khả năng nhất

Thực hiện phân đoạn bằng cách xem xét tất cả các chuỗi từ và ranh giới có thể có

Không phải lúc nào cũng đưa ra chuỗi từ có khả năng nhất vì mỗi chuỗi từ là tổng của nhiều chuỗi trạng thái

Jelinek đã phát minh ra A^* vào năm 1969 một cách để tìm chuỗi từ có khả năng xảy ra nhất

trong đó “ chi phí bước ” là $-\log P(w_i|w_{i-1})$

DBN để nhận dạng giọng nói

Cũng dễ dàng thêm các biến cho, ví dụ: giới tính, giọng nói, tốc độ.
Zweig và Russell (1998) cho thấy mức giảm lỗi tới 40

Tóm tắt

Từ giữa những năm 1970, nhận dạng giọng nói đã được xây dựng dưới dạng suy luận xác suất

Bằng chứng = tín hiệu giọng nói, biến ẩn = chuỗi từ và âm thanh

Các hiệu ứng “Context” (coarticulation, v.v.) được xử lý bằng cách tăng cường trạng thái

Sự thay đổi trong lời nói của con người (tốc độ, âm sắc, v.v.) và tiếng ồn xung quanh

làm cho nhận dạng giọng nói liên tục trong cài đặt thực tế trở thành một vấn đề mở