

CÁC QUYẾT ĐỊNH PHỨC TẠP (COMPLEX DECISIONS)

CHƯƠNG 17, PHẦN 1–3

Phác thảo

- ◇ Các vấn đề về quyết định tuần tự
- ◇ Lặp lại giá trị
- ◇ Lặp lại chính sách

Các vấn đề về quyết định tuần tự

Ví dụ MDP

$$s \in S \quad a \in A$$

Kỳ $s \in S$, hành động $a \in A$

Mô hình $T(s, a, s') \equiv P(s'|s, a) =$ xác suất a trong s dẫn đến s'

Chức năng thưởng $R(s)$ (hoặc $R(s, a)$, $R(s, a, s')$)

$$= \begin{cases} -0.04 & \text{(small penalty) for nonterminal states} \\ \pm 1 & \text{for terminal states} \end{cases}$$

Giải quyết MDP

Trong các bài toán tìm kiếm, mục đích là tìm một chuỗi tối ưu

Trong MDP, mục tiêu là tìm ra một *Policy* tối ưu $\pi(s)$

tức là hành động tốt nhất cho mọi trạng thái có thể s

(vì không thể đoán trước được mình sẽ đi về đâu)

Chính sách tối ưu tối đa hóa (giả sử) *tổng phần thưởng dự kiến*

Chính sách tối ưu khi hình phạt của tiểu bang $R(s)$ là $-0,04$:

Rủ ro và phần thưởng

Tiện ích của chuỗi trạng thái

Cần hiểu các ưu tiên giữa *chuỗi* trạng thái

Thường xem xét tùy chọn cố định trên chuỗi phần thưởng:

$$[r, r_0, r_1, r_2, \dots] \succ [r, r'_0, r'_1, r'_2, \dots] \Leftrightarrow [r_0, r_1, r_2, \dots] \succ [r'_0, r'_1, r'_2, \dots]$$

Định lý: chỉ có hai cách để kết hợp phần thưởng theo thời gian.

1) Hàm tiện ích *Additive*:

$$U([s_0, s_1, s_2, \dots]) = R(s_0) + R(s_1) + R(s_2) + \dots$$

2) Hàm tiện ích *Giảm giá*:

$$U([s_0, s_1, s_2, \dots]) = R(s_0) + \gamma R(s_1) + \gamma^2 R(s_2) + \dots$$

trong đó γ là hệ số chiết khấu

Tiện ích của các trạng thái

Tiện ích của một *state* (hay còn gọi là *value*) được xác định là

$U(s) =$
tổng số phần thưởng dự kiến (được chiết khấu) (cho đến khi chấm dứt)

giả sử hành động tối ưu

Với những tiện ích của các bang, việc lựa chọn hành động tốt nhất chỉ là MEU:

tối đa hóa lợi ích mong đợi của những người kế nhiệm trực tiếp

Tiện ích tiếp theo.

Vấn đề: các tiện ích cộng thêm có thời gian sống vô hạn $\Rightarrow$ là vô hạn

1) Chân trời hữu hạn: kết thúc tại một *thời gian cố định* T

Chính sách $\Rightarrow$ không cố định: $\pi(s)$ phụ thuộc vào thời gian còn lại

2) (Các) trạng thái hấp thụ: w/ prob. 1, tác nhân cuối cùng “ chết ” đối với bất kỳ π

$\Rightarrow$ Tiện ích dự kiến của mọi trạng thái là hữu hạn

3) Chiết khấu: giả sử $\gamma < 1$, $R(s) \leq R_{\max}$,

$$U([s_0, \dots s_\infty]) = \sum_{t=0}^{\infty} \gamma^t R(s_t) \leq R_{\max} / (1 - \gamma)$$

Đường chân trời ngắn hơn $\gamma \Rightarrow$ nhỏ hơn

4) Tối đa hóa lợi ích hệ thống = phần thưởng trung bình mỗi bước thời gian

Định lý: chính sách tối ưu có mức tang không đổi sau thoág qua ban đầu
Ví dụ: kế hoạch hàng ngày của tài xế taxi đưa đón hành khách

Lập trình động: phương trình Bellman

Định nghĩa về tính hữu dụng của các trạng thái dẫn đến một mối quan hệ đơn giản giữa Tiềm ích của các nước lân cận:

tổng số phần thưởng dự kiến

= phần thưởng hiện tại

+ $\gamma \times$ tổng số phần thưởng dự kiến sau khi thực hiện hành động tốt nhất

Phương trình Bellman (1957):

$$U(s) = R(s) + \gamma \max_a \sum_{s'} U(s') T(s, a, s')$$

$$U(1, 1) = -0.04$$

$$+ \gamma \max\{0.8U(1, 2) + 0.1U(2, 1) + 0.1U(1, 1), \quad up$$

$$0.9U(1, 1) + 0.1U(1, 2)$$

left

$$0.9U(1, 1) + 0.1U(2, 1)$$

down

Một phương trình trên mỗi trạng thái = n phi tuyến phương trình trong n ẩn số

Thuật toán lặp giá trị

Idea: Bắt đầu với các giá trị tiện ích tùy ý

Cập nhật để làm cho chúng nhất quán cục bộ với Bellman eqn.

Tối ưu toàn cầu nhất quán cục bộ $\Rightarrow$ ở mọi nơi

Lặp lại đồng thời cho mọi s cho đến khi “không thay đổi”

$$U(s) \leftarrow R(s) + \gamma \max_a \sum_{s'} U(s') T(s, a, s') \quad \text{for all } s$$

Hội tụ

Xác định max-norm $\|U\| = \max_s |U(s)|$,
vì vậy $\|U - V\| =$ chênh lệch tối đa giữa U và V

Đặt U^t và U^{t+1} là các giá trị gần đúng liên tiếp của hữu dụng thực U

Định lý: Đối với hai phép tính gần đúng bất kỳ U^t và V^t

$$\|U^{t+1} - V^{t+1}\| \leq \gamma \|U^t - V^t\|$$

Tức là, mọi phép tính gần đúng khác biệt đều phải tiến gần nhau hơn
vì vậy, đặc biệt, bất kỳ phép tính gần đúng nào cũng phải tiến gần hơn đến
giá trị thực U

và sự lặp lại giá trị hội tụ thành một giải pháp duy nhất, ổn định, tối ưu

Định lý: nếu $\|U^{t+1} - U^t\| < \epsilon$ thì $\|U^{t+1} - U\| < 2\epsilon\gamma/(1 - \gamma)$

Tức là, khi thay đổi trong U^t trở nên nhỏ, chúng ta gần như đã hoàn tất.

Chính sách MEU sử dụng U^t có thể tối ưu từ lâu trước khi hội tụ các giá trị

Lặp lại chính sách

Howard, 1960: tìm kiếm đồng thời các giá trị chính sách và tiện ích tối ưu

Thuật toán:

$\pi \leftarrow$ chính sách ban đầu tùy ý

lặp lại cho đến khi không có thay đổi nào trong π

các tiện ích tính toán được cung cấp π

cập nhật π như thể các tiện ích đã chính xác (tức là MEU cục bộ)

Để tính toán các tiện ích được xác định giá trị π (cố định):

$$U(s) = R(s) + \gamma \sum_{s'} U(s') T(s, \pi(s), s') \quad \text{for all } s$$

tức là, n phương trình tuyến tính đồng thời trong n ẩn số, giải quyết trong $O(n^3)$

Lặp lại chính sách đã sửa đổi

Việc lặp lại chính sách thường hội tụ trong một vài lần lặp, nhưng mỗi lần đều tốn kém

*Ý tưởng: sử dụng một vài bước lặp giá trị (nhưng đã sửa π)
bắt đầu từ hàm giá trị được tạo lần trước
để tạo ra bước xác định giá trị gần đúng.*

Thường hội tụ nhanh hơn nhiều so với VI hoặc PI thuần túy

Dẫn đến các thuật toán tổng quát hơn trong đó cập nhật giá trị Bellman và cập nhật chính sách của Howard có thể được thực hiện cục bộ theo bất kỳ thứ tự nào

Thuật toán Học tăng cường hoạt động bằng cách thực hiện như vậy cập nhật dựa trên các chuyển đổi được quan sát được thực hiện theo cách chưa biết ban đầu môi trường

Khả năng quan sát một phần

POMDP có mô hình quan sát $O(s, e)$ xác định xác suất mà đại lý thu được bằng chứng e khi ở trạng thái s

Tác nhân không biết nó đang ở trạng thái nào

$\Rightarrow$ *nói về chính sách thật vô nghĩa $\pi(s)!!$*

Định lý (Astrom, 1965): *chính sách tối ưu trong POMDP là một hàm*

$\pi(b)$ trong đó b là trạng thái niềm tin (phân bố xác suất trên các trạng thái)

Có thể chuyển đổi POMDP thành MDP trong không gian trạng thái niềm tin, trong đó

$T(b, a, b')$ là xác suất trạng thái niềm tin mới là b'

cho rằng trạng thái niềm tin hiện tại là b và tác nhân thực hiện a .

Tức là về cơ bản là bước cập nhật lọc

Tiếp theo khả năng quan sát một phần

Giải pháp tự động bao gồm hành vi thu thập thông tin

Nếu có trạng thái n thì b là một vectơ có giá trị thực theo chiều n

$\Rightarrow$ việc giải quyết POMDP rất (thực sự là PSPACE-) rất khó!

Thế giới thực là một POMDP (ban đầu không xác định được T và O)