

HỌC TÀNG CƯỜNG (REINFORCEMENT LEARNING)

CHƯƠNG 21, PHẦN 1–4

Phác thảo

- ◇ Các ví dụ
- ◇ Học một hàm giá trị cho một chính sách cố định
 - học qua khác biệt thời gian (temporal difference learning)
- ◇ Học Q (Q-learning)
- ◇ Xấp xỉ hàm (Function approximation)
- ◇ Khám phá (Exploration)

Học tăng cường

- ◇ Tác tử nằm trong môi trường MDP hoặc POMDP
- ◇ Phản hồi duy nhất cho việc học là nhận thức + phần thưởng (percept + reward)
- ◇ Tác tử phải học một chính sách dưới dạng nào đó:
 - mô hình chuyển tiếp $T(s, a, s')$ cộng với hàm giá trị $U(s)$
 - $Q(a, s)$ = tiện ích kỳ vọng nếu chúng ta thực hiện a trong s và sau đó hành động tối ưu
 - chính sách $\pi(s)$

Ví dụ: Thế giới 4x3

$$(1, 1) \xrightarrow{-0.04} (1, 2) \xrightarrow{-0.04} (1, 3) \xrightarrow{-0.04} (1, 2) \xrightarrow{-0.04} (1, 3) \xrightarrow{-0.04} \dots (4, 3) + 1$$

$$(1, 1) \xrightarrow{-0.04} (1, 2) \xrightarrow{-0.04} (1, 3) \xrightarrow{-0.04} (2, 3) \xrightarrow{-0.04} (3, 3) \xrightarrow{-0.04} \dots (4, 3) + 1$$

$$(1, 1) \xrightarrow{-0.04} (2, 1) \xrightarrow{-0.04} (3, 1) \xrightarrow{-0.04} (3, 2) \xrightarrow{-0.04} (4, 2) - 1$$

Ví dụ: Backgammon

- ◇ Phần thưởng cho thắng/thua chỉ có ở trạng thái kết thúc, còn lại là 0
- ◇ TDGammon học $\hat{U}(s)$, biểu diễn dưới dạng mạng nơ-ron 3 lớp
- ◇ Kết hợp với tìm kiếm độ sâu 2 hoặc 3, trở thành một trong ba người chơi giỏi nhất thế giới

Ví dụ: Học ở động vật

- ◇ RL đã được nghiên cứu thực nghiệm hơn 60 năm trong tâm lý học
- ◇ Phần thưởng: thức ăn, đau đớn, cơn đói, được phẩm giải trí, v.v.
- ◇ Ví dụ: ong học kế hoạch tìm kiếm thức ăn gần tối ưu trong cánh đồng hoa nhân tạo với nguồn mật được kiểm soát
- ◇ Ong có một kết nối nơ-ron trực tiếp từ bộ phận đo lường mật nạp vào tới vùng lập kế hoạch vận động

Ví dụ: Trục thang tự trị

◇ Phần thưởng = - bình phương độ lệch so với trạng thái mong muốn



Ví dụ: Trực thăng tự trị



Học qua khác biệt thời gian (Temporal difference learning)

◇ Cố định một chính sách π , thực thi nó, học $U^\pi(s)$

◇ Phương trình Bellman:



$$U^\pi(s) = R(s) + \gamma \sum_{s'} T(s, \pi(s), s') U^\pi(s')$$

◇ Cập nhật TD điều chỉnh ước tính tiện ích để thống nhất với phương trình Bellman:

$$U^\pi(s) \leftarrow U^\pi(s) + \alpha (R(s) + \gamma U^\pi(s') - U^\pi(s))$$

◇ Về cơ bản sử dụng lấy mẫu từ môi trường thay vì tính tổng chính xác

Hiệu suất của TD



Học Q (Q-learning)

◇ Một nhược điểm của việc học $U(s)$: vẫn cần $T(s, a, s')$ để đưa ra quyết định

◇ $Q(a, s)$ = tiện ích kỳ vọng nếu chúng ta thực hiện a trong s và sau đó hành động tối ưu

◇ Phương trình Bellman:

$$Q(a, s) = R(s) + \gamma \sum_{s'} T(s, \pi(s), s') \max_{a'} Q(a', s')$$

◇ Cập nhật Q-learning:

$$Q(a, s) \leftarrow Q(a, s) + \alpha \left(R(s) + \gamma \max_{a'} Q(a', s') - Q(a, s) \right)$$

◇ Q-learning là một phương pháp không cần mô hình (model-free) để học và ra quyết định (vì vậy không thể sử dụng mô hình để ràng buộc các giá trị Q, mô phỏng trong tư duy, v.v.)

Xấp xỉ hàm (Function approximation)

◇ Đối với các bài toán thực tế, không thể biểu diễn U hoặc Q dưới dạng bảng!!

◇ Thông thường sử dụng xấp xỉ hàm tuyến tính:

$$\hat{U}_\theta(s) = \theta_1 f_1(s) + \theta_2 f_2(s) + \dots + \theta_n f_n(s)$$

◇ Sử dụng một bước gradient để sửa đổi các tham số θ :



$$\theta_i \leftarrow \theta_i + \alpha \left[R(s) + \gamma \hat{U}_\theta(s') - \hat{U}_\theta(s) \right] \frac{\partial \hat{U}_\theta(s)}{\partial \theta_i}$$

$$\theta_i \leftarrow \theta_i + \alpha \left[R(s) + \gamma \max_{a'} \hat{Q}_\theta(a', s') - \hat{Q}_\theta(a, s) \right] \frac{\partial \hat{Q}_\theta(a, s)}{\partial \theta_i}$$

◇ Thường rất hiệu quả trong thực tế, nhưng không đảm bảo sự hội tụ

Khám phá (Exploration)

◇ Tác tử nên cư xử như thế nào? Chọn hành động với tiện ích kỳ vọng cao nhất?



Exploration vs. exploitation: o

Chapter 21, Sections 1-4 13

◇ Khám phá vs. Khai thác (Exploration vs. exploitation): thỉnh thoảng thử các hành động "dưới mức tối ưu"!!

Tóm tắt

- ◇ Các phương pháp học tăng cường tìm ra các giải pháp xấp xỉ cho MDP
- ◇ Làm việc trực tiếp từ kinh nghiệm trong môi trường
- ◇ Không cần phải được cung cấp mô hình chuyển tiếp từ trước
- ◇ Q-learning hoàn toàn không cần mô hình (model-free)
- ◇ Xấp xỉ hàm (ví dụ: kết hợp tuyến tính của các đặc trưng) giúp RL mở rộng cho các MDP rất lớn
- ◇ Sự khám phá là cần thiết để hội tụ đến các giải pháp tối ưu