

CHƯƠNG 14: SUY DIỄN XÁC SUẤT THEO THỜI GIAN

TRÍ TUỆ NHÂN TẠO - ARTIFICIAL INTELLIGENCE

Nội dung Chương 14

- ◇ 14.1 Thời gian và Sự Không Chắc Chắn (Time and Uncertainty)
- ◇ 14.2 Suy luận trong các Mô hình Thời gian
- ◇ 14.3 Mô hình Markov ẩn (Hidden Markov Models - HMM)
- ◇ 14.4 Bộ lọc Kalman (Kalman Filters)
- ◇ 14.5 Mạng Bayes động (Dynamic Bayesian Networks - DBN)

14.1 Thời gian và Sự Không Chắc Chắn

- ◇ Các chương trước ta giả định thế giới tĩnh (static), không thay đổi theo thời gian.
- ◇ Trong thực tế, thế giới luôn biến động. Tác nhân cần theo dõi trạng thái qua các bước thời gian (time steps).
- ◇ **Biến trạng thái (State variables) X_t** : Mô tả trạng thái của thế giới tại thời điểm t (ẩn, không quan sát trực tiếp được toàn bộ).
- ◇ **Biến bằng chứng (Evidence variables) E_t** : Quan sát nhận được từ cảm biến tại thời điểm t .

14.1 Giả định Markov (Markov Assumption)

◇ Nếu trạng thái hiện tại phụ thuộc vào toàn bộ quá khứ, không gian trạng thái sẽ tăng vô hạn.

◇ **Giả định Markov (Markov Assumption):** Quá trình diễn biến của trạng thái chỉ phụ thuộc vào một số hữu hạn các trạng thái gần nhất trong quá khứ.

◇ **Tiến trình Markov bậc một (First-order Markov process):** Trạng thái hiện tại X_t chỉ phụ thuộc vào trạng thái ngay trước đó X_{t-1} .

- $\mathbf{P}(X_t|X_{0:t-1}) = \mathbf{P}(X_t|X_{t-1})$

14.1 Mô hình chuyển đổi và Mô hình cảm biến

◇ **Mô hình chuyển đổi (Transition Model):** Xác định xác suất trạng thái thế giới tiếp diễn ra sao từ $t - 1$ sang t .

- Được biểu diễn qua $\mathbf{P}(X_t|X_{t-1})$.
- Giả định tĩnh (Stationary process): Quy luật chuyển đổi không thay đổi theo thời gian.

◇ **Mô hình cảm biến (Sensor Model):** Xác định xác suất cảm biến thu được kết quả $\mathbf{e}_t$ khi ở trạng thái X_t .

- Còn gọi là mô hình quan sát: $\mathbf{P}(E_t|X_t)$.
- Giả định: Bằng chứng E_t chỉ phụ thuộc vào trạng thái hiện tại X_t .

Mô hình Thời gian: Cấu trúc cơ bản




Figure 1: Mô hình Bayes cơ bản cho chuỗi thời gian: Các trạng thái và bằng chứng.

14.2 Suy luận trong các Mô hình Thời gian

◇ 1. Lọc (Filtering) - Theo dõi (Monitoring):

- Nhiệm vụ: Tính phân phối trạng thái hiện tại dựa trên tất cả bằng chứng từ trước đến nay.
- Công thức: $\mathbf{P}(X_t | \mathbf{e}_{1:t})$.
- Là bài toán quan trọng nhất để tác nhân nhận thức môi trường.

◇ 2. Dự đoán (Prediction):

- Nhiệm vụ: Dự báo trạng thái tương lai.
- Công thức: $\mathbf{P}(X_{t+k} | \mathbf{e}_{1:t})$ với $k > 0$.

14.2 Suy luận trong các Mô hình Thời gian (Tiếp)

◇ 3. Làm mượt (Smoothing) - Hindsight:

- Nhiệm vụ: Đánh giá lại trạng thái trong quá khứ khi đã biết thêm tương lai.
- Công thức: $\mathbf{P}(X_k | \mathbf{e}_{1:t})$ với $0 \leq k < t$.
- Độ chính xác cao hơn so với lúc chỉ có Filtering tại thời điểm k .

◇ 4. Tìm chuỗi có khả năng nhất (Most likely explanation):

- Nhiệm vụ: Tìm chuỗi trạng thái $\mathbf{x}_{1:t}$ có xác suất xảy ra cao nhất sinh ra chuỗi quan sát $\mathbf{e}_{1:t}$.
- Ứng dụng phổ biến nhất là nhận dạng giọng nói (Thuật toán Viterbi).

14.3 Mô hình Markov ẩn (Hidden Markov Models - HMM)

- ◇ **Định nghĩa HMM:** Là một mô hình thời gian trong đó trạng thái hệ thống X_t được biểu diễn bởi một biến rời rạc duy nhất.
- ◇ Có thể có nhiều trạng thái khả thi, nhưng tại thời điểm t , hệ thống chỉ ở một trạng thái cụ thể.
- ◇ Mô hình chuyển đổi $\mathbf{P}(X_t|X_{t-1})$ trở thành một **Ma trận chuyển đổi** (Transition matrix) $\mathbf{T}_{ij} = P(X_t = j|X_{t-1} = i)$.
- ◇ HMM được coi là cấu trúc nền tảng cho việc nhận dạng mẫu tuần tự.

14.3 Các thuật toán trên HMM

◇ Bằng cách sử dụng đại số tuyến tính, việc cập nhật Filtering trên HMM được thực hiện bằng phép nhân ma trận cực kỳ tốc độ:

◇ **Phương trình cập nhật tiến (Forward update):**

- $\mathbf{f}_{1:t+1} = \alpha \mathbf{O}_{t+1} \mathbf{T}^T \mathbf{f}_{1:t}$

- Trong đó: $\mathbf{O}_{t+1}$ là ma trận đường chéo chứa xác suất cảm biến, $\mathbf{T}$ là ma trận chuyển đổi.

◇ **Thuật toán Forward-Backward:** Sự kết hợp giữa thông điệp truyền tới (Forward) để Filtering và truyền ngược (Backward) để Smoothing, có thể giải quyết trong thời gian $\mathcal{O}(|X|^2 t)$.

Thuật toán Forward-Backward

function FORWARD-BACKWARD(**ev**, *prior*) **returns** a vector of probability distributions

inputs: **ev**, a vector of evidence values for steps $1, \dots, t$

prior, the prior distribution on the initial state, $\mathbf{P}(\mathbf{X}_0)$

local variables: **fv**, a vector of forward messages for steps $0, \dots, t$

b, a representation of the backward message, initially all 1s

sv, a vector of smoothed estimates for steps $1, \dots, t$

fv[0] $\leftarrow$ *prior*

for $i = 1$ **to** t **do**

fv[i] $\leftarrow$ FORWARD(**fv**[$i - 1$], **ev**[i])

for $i = t$ **down to** 1 **do**

sv[i] $\leftarrow$ NORMALIZE(**fv**[i] $\times$ **b**)

b $\leftarrow$ BACKWARD(**b**, **ev**[i])

return **sv**

Figure 2: Thuật toán FORWARD-BACKWARD: Tính toán sự phân phối chính xác bằng cách lan truyền tiến và lùi.

Thuật toán Làm mượt độ trễ cố định

function FIXED-LAG-SMOOTHING(e_t, hmm, d) **returns** a distribution over $\mathbf{X}_{t-d}$

inputs: e_t , the current evidence for time step t
 hmm , a hidden Markov model with $S \times S$ transition matrix $\mathbf{T}$
 d , the length of the lag for smoothing

persistent: t , the current time, initially 1
 $\mathbf{f}$, the forward message $\mathbf{P}(X_t | e_{1:t})$, initially $hmm.PRIOR$
 $\mathbf{B}$, the d -step backward transformation matrix, initially the identity matrix
 $e_{t-d:t}$, double-ended list of evidence from $t-d$ to t , initially empty

local variables: $\mathbf{O}_{t-d}, \mathbf{O}_t$, diagonal matrices containing the sensor model information

add e_t to the end of $e_{t-d:t}$
 $\mathbf{O}_t \leftarrow$ diagonal matrix containing $\mathbf{P}(e_t | X_t)$
if $t > d$ **then**
 $\mathbf{f} \leftarrow \text{FORWARD}(\mathbf{f}, e_{t-d})$
 remove e_{t-d-1} from the beginning of $e_{t-d:t}$
 $\mathbf{O}_{t-d} \leftarrow$ diagonal matrix containing $\mathbf{P}(e_{t-d} | X_{t-d})$
 $\mathbf{B} \leftarrow \mathbf{O}_{t-d}^{-1} \mathbf{T}^{-1} \mathbf{B} \mathbf{O}_t$
else $\mathbf{B} \leftarrow \mathbf{B} \mathbf{O}_t$
 $t \leftarrow t + 1$
if $t > d + 1$ **then return** NORMALIZE($\mathbf{f} \times \mathbf{B} \mathbf{1}$) **else return** null


Figure 3: Thuật toán FIXED-LAG-SMOOTHING: Cập nhật Smoothing trực tuyến với một độ trễ cố định.

14.3 Ví dụ điển hình của HMM


◇ Bài toán định vị Robot (Localization):

- Một robot di chuyển trong mê cung mù mịt (không có GPS, cảm biến siêu âm bị nhiễu).
- Robot sử dụng HMM để suy luận ra vị trí có khả năng nhất của nó dựa trên các quan sát dọc đường.

Bài toán Định vị Robot với HMM



(a) Posterior distribution over robot location after $E_1 = 1011$



(b) Posterior distribution over robot location after $E_1 = 1011, E_2 = 1010$

Figure 4: Quá trình Robot sử dụng HMM để lọc trạng thái và suy luận ra vị trí có khả năng nhất trong mê cung.

14.4 Bộ lọc Kalman (Kalman Filters)

- ◇ **Vấn đề của HMM:** Không gian trạng thái rời rạc không phù hợp với các hệ thống vật lý liên tục (vị trí, vận tốc thực của ô tô, máy bay).
- ◇ Nếu chi nhỏ không gian liên tục thành các ô vuông rời rạc, ma trận chuyển đổi sẽ phình to không tưởng.
- ◇ **Bộ lọc Kalman (Kalman Filter):**
 - Giải pháp chuẩn mực cho biến liên tục, được dùng trong hành trình Apollo lên mặt trăng và mọi hệ thống Radar ngày nay.
 - Giả định mô hình chuyển đổi và mô hình cảm biến đều tuyến tính, với nhiễu Gaussian.

Cấu trúc Bộ lọc Kalman




Figure 5: Sự chuyển đổi trạng thái liên tục theo thời gian trong Bộ lọc Kalman.

14.4 Đặc tính Phân phối Gaussian trong Kalman Filter

- ◇ Toàn bộ sự phân bố niềm tin (Belief state) $\mathbf{P}(X_t|\mathbf{e}_{1:t})$ được biểu diễn bằng một phân phối chuẩn (Gaussian distribution).
- ◇ Một phân phối Gaussian nhiều chiều chỉ cần 2 tham số để mô tả hoàn toàn:
 - Vector trung bình (Mean vector): μ_t (vị trí ước lượng nhất).
 - Ma trận hiệp phương sai (Covariance matrix): Σ_t (độ bất định).
- ◇ Quá trình Filtering của Kalman biến đổi các tham số μ, Σ theo thời gian với các ma trận tuyến tính cố định.

14.4 Ví dụ ứng dụng Kalman Filter

◇ Theo dõi mục tiêu chuyển động (Tracking):

- Giả sử chim bay theo đường thẳng với vận tốc nhiễu loạn ngẫu nhiên. Camera quan sát vị trí bị mờ.
- Bộ lọc Kalman làm "mượt" (Smoothing) quỹ đạo quan sát nhiễu thành một quỹ đạo chuẩn xác gần sát với quỹ đạo thực của mục tiêu.

Kết quả của Lọc và Làm mượt Kalman




Figure 6: Minh họa khả năng tái tạo quỹ đạo mượt mà từ những điểm dữ liệu nhiễu loạn.

14.5 Mạng Bayes động (Dynamic Bayesian Networks - DBN)

◇ Hạn chế của Kalman Filter và HMM:

- HMM sử dụng 1 biến trạng thái lớn nên phức tạp tăng số mũ.
- Kalman Filter bắt buộc mọi thứ tuyến tính và Gaussian.

◇ **Mạng DBN:** Là sự mở rộng của mạng Bayes cho các mô hình thời gian.

- Trạng thái thế giới X_t được chia thành nhiều biến (variables).
- Thừa hưởng khả năng nén bộ nhớ của mạng Bayes và sự tiến triển thời gian của HMM.

Cấu trúc Mạng Bayes động (DBN)




Figure 7: Cấu trúc mạng DBN chia nhỏ các biến trạng thái, tránh không gian trạng thái phình to theo cấp số nhân.

14.5 Bộ lọc Hạt (Particle Filtering)

◇ Suy luận chính xác trong mạng DBN (bằng Roll-out hoặc Variable Elimination) thường bất khả thi do kích thước không gian cực lớn.

◇ **Lọc Hạt (Particle Filtering - Phân phối Monte Carlo tuần tự):**

- Là thuật toán suy luận xấp xỉ đột phá giải quyết bài toán Filtering trong DBN.
- Ý tưởng cốt lõi: Biểu diễn phân phối xác suất liên tục thông qua một quần thể các **Hạt (Particles)** (mỗi hạt là một trạng thái phỏng đoán).

◇ Quần thể hạt sẽ tập trung ở những khu vực có xác suất cao.

14.5 Các bước của thuật toán Bộ lọc Hạt

◇ Ba bước lặp của quá trình Filtering với Hạt:

1. **Lan truyền (Propagate):** Đẩy mỗi hạt x từ thời điểm t sang $t + 1$ dựa trên mô hình chuyển đổi $\mathbf{P}(X_{t+1}|x)$.
2. **Gán trọng số (Weight):** Chấm điểm từng hạt dựa trên mô hình cảm biến $\mathbf{P}(\mathbf{e}_{t+1}|x)$. Hạt nào khớp với thực tế sẽ có trọng lượng lớn.
3. **Lấy mẫu lại (Resample):** Rút ngẫu nhiên một quần thể hạt mới có cùng kích thước N từ quần thể cũ, với xác suất tỉ lệ thuận với trọng số hạt. (Survival of the fittest).

Thuật toán Bộ lọc Hạt (Particle Filtering)

function PARTICLE-FILTERING($\mathbf{e}, N, dbn$) **returns** a set of samples for the next time step

inputs: $\mathbf{e}$, the new incoming evidence

N , the number of samples to be maintained

dbn , a DBN defined by $\mathbf{P}(\mathbf{X}_0)$, $\mathbf{P}(\mathbf{X}_1 | \mathbf{X}_0)$, and $\mathbf{P}(\mathbf{E}_1 | \mathbf{X}_1)$

persistent: S , a vector of samples of size N , initially generated from $\mathbf{P}(\mathbf{X}_0)$

local variables: W , a vector of weights of size N

for $i = 1$ to N **do**

$S[i] \leftarrow$ sample from $\mathbf{P}(\mathbf{X}_1 | \mathbf{X}_0 = S[i])$ *// step 1*

$W[i] \leftarrow \mathbf{P}(\mathbf{e} | \mathbf{X}_1 = S[i])$ *// step 2*

$S \leftarrow$ WEIGHTED-SAMPLE-WITH-REPLACEMENT(N, S, W) *// step 3*

return S

Figure 8: Thuật toán PARTICLE-FILTERING: Lọc bằng phương pháp Monte Carlo, cực kỳ hiệu quả với DBN phi tuyến.

Tóm tắt Chương 14

- ◇ Suy luận xác suất theo thời gian là năng lực sống còn để AI hoạt động trong không gian vật lý thực.
- ◇ **Mô hình Markov ẩn (HMM):** Ma trận toán học thanh lịch cho các bài toán rời rạc.
- ◇ **Bộ lọc Kalman (Kalman Filter):** Trái tim của mọi hệ thống dẫn đường, chuyên trị thế giới liên tục nhưng tuyến tính.
- ◇ **Bộ lọc Hạt (Particle Filter) và DBN:** Giải pháp đỉnh cao đương đại để đối phó với thế giới phi tuyến, đa biến và cực kỳ phức tạp. Mọi robot tiên tiến và xe tự lái hiện nay đều dựa trên công nghệ này.