

CHƯƠNG 24: XỬ LÝ NGÔN NGỮ TỰ NHIÊN (NATURAL LANGUAGE PROCESSING)

TRÍ TUỆ NHÂN TẠO - ARTIFICIAL INTELLIGENCE

Nội dung Chương 24

- ◇ 24.1 Mô hình Ngôn ngữ (Language Models)
- ◇ 24.2 Ngữ pháp (Grammar)
- ◇ 24.3 Phân tích cú pháp (Parsing)
- ◇ 24.4 Ngữ pháp Tăng cường (Augmented Grammars)
- ◇ 24.5 Những phức tạp của ngôn ngữ tự nhiên thực tế
- ◇ 24.6 Các tác vụ Ngôn ngữ Tự nhiên (Natural Language Tasks)

24.1 Mô hình Ngôn ngữ (Language Models)

◇ **Xử lý ngôn ngữ tự nhiên (NLP):** Là lĩnh vực giao thoa giữa Khoa học máy tính, AI và Ngôn ngữ học. Mục tiêu là cho máy tính khả năng hiểu, diễn dịch và thao tác với ngôn ngữ của con người.

◇ **Mô hình Ngôn ngữ:** Là mô hình gán xác suất $P(w_{1:N})$ cho một chuỗi các từ $w_1, w_2, \dots, w_N$. Giúp dự đoán từ tiếp theo hoặc đánh giá độ tự nhiên của một câu.

◇ **Mô hình N-gram:** Đơn giản hóa bằng giả định Markov. Xác suất của từ thứ i chỉ phụ thuộc vào $N - 1$ từ đứng ngay trước nó.

$$P(w_i | w_1, w_2, \dots, w_{i-1}) \approx P(w_i | w_{i-N+1}, \dots, w_{i-1})$$

◇ **Gán nhãn từ loại (POS Tagging):** Phân loại mỗi từ trong câu vào một từ loại (Danh từ, Động từ, Tính từ...).

Tag	Word	Description	Tag	Word	Description
CC	<i>and</i>	Coordinating conjunction	PRP\$	<i>your</i>	Possessive pronoun
CD	<i>three</i>	Cardinal number	RB	<i>quickly</i>	Adverb
DT	<i>the</i>	Determiner	RBR	<i>quicker</i>	Adverb, comparative
EX	<i>there</i>	Existential there	RBS	<i>quickest</i>	Adverb, superlative
FW	<i>per se</i>	Foreign word	RP	<i>off</i>	Particle
IN	<i>of</i>	Preposition	SYM	<i>+</i>	Symbol
JJ	<i>purple</i>	Adjective	TO	<i>to</i>	to
JJR	<i>better</i>	Adjective, comparative	UH	<i>eureka</i>	Interjection
JJS	<i>best</i>	Adjective, superlative	VB	<i>talk</i>	Verb, base form
LS	<i>I</i>	List item marker	VBD	<i>talked</i>	Verb, past tense
MD	<i>should</i>	Modal	VBG	<i>talking</i>	Verb, gerund
NN	<i>kitten</i>	Noun, singular or mass	VCN	<i>talked</i>	Verb, past participle
NNS	<i>kittens</i>	Noun, plural	VBP	<i>talk</i>	Verb, non-3rd-sing
NNP	<i>Ali</i>	Proper noun, singular	VBZ	<i>talks</i>	Verb, 3rd-sing
NNPS	<i>Fords</i>	Proper noun, plural	WDT	<i>which</i>	Wh-determiner
PDT	<i>all</i>	Predeterminer	WP	<i>who</i>	Wh-pronoun
POS	<i>'s</i>	Possessive ending	WP\$	<i>whose</i>	Possessive wh-pronoun
PRP	<i>you</i>	Personal pronoun	WRB	<i>where</i>	Wh-adverb
\$	<i>\$</i>	Dollar sign	#	<i>#</i>	Pound sign
"	<i>'</i>	Left quote	"	<i>'</i>	Right quote
(	<i>[</i>	Left parenthesis	)	<i>]</i>	Right parenthesis
,	<i>,</i>	Comma	.	<i>!</i>	Sentence end
:	<i>;</i>	Mid-sentence punctuation			

Figure 1: Ví dụ về bộ 45 thẻ từ loại (POS tags) được sử dụng trong tập dữ liệu chuẩn Penn Treebank.

24.2 Ngữ pháp (Grammar)

◇ **Cú pháp (Syntax):** Quy tắc kết hợp các từ lại với nhau để tạo thành các cụm từ và câu đúng ngữ pháp.

◇ **Ngữ pháp phi ngữ cảnh xác suất (PCFG):**

- Mỗi quy tắc sinh (Production rule) có dạng $X \rightarrow Y_1 Y_2 \dots Y_k$ đi kèm với một xác suất p .
- "Phi ngữ cảnh": Quy tắc cho cụm danh từ ở đầu câu áp dụng hết như ở cuối câu.

<i>S</i>	→ <i>NP VP</i>	[0.90]	I + feel a breeze
	<i>S Conj S</i>	[0.10]	I feel a breeze + and + It stinks
<i>NP</i>	→ <i>Pronoun</i>	[0.25]	I
	<i>Name</i>	[0.10]	Ali
	<i>Noun</i>	[0.10]	pits
	<i>Article Noun</i>	[0.25]	the + wumpus
	<i>Article Adjs Noun</i>	[0.05]	the + smelly dead + wumpus
	<i>Digit Digit</i>	[0.05]	3 4
	<i>NP PP</i>	[0.10]	the wumpus + in 1 3
	<i>NP RelClause</i>	[0.05]	the wumpus + that is smelly
	<i>NP Conj NP</i>	[0.05]	the wumpus + and + I
<i>VP</i>	→ <i>Verb</i>	[0.40]	stinks
	<i>VP NP</i>	[0.35]	feel + a breeze
	<i>VP Adjective</i>	[0.05]	smells + dead
	<i>VP PP</i>	[0.10]	is + in 1 3
	<i>VP Adverb</i>	[0.10]	go + ahead
<i>Adjs</i>	→ <i>Adjective</i>	[0.80]	smelly
	<i>Adjective Adjs</i>	[0.20]	smelly + dead
<i>PP</i>	→ <i>Prep NP</i>	[1.00]	to + the east
<i>RelClause</i>	→ <i>RelPro VP</i>	[1.00]	that + is smelly

Figure 2: Một phần của một Ngữ pháp Phi ngữ cảnh Xác suất (PCFG), định nghĩa cách các thành phần cú pháp kết hợp.

24.2 Từ vựng (Lexicon)

◇ Một phần quan trọng của ngôn ngữ là **Từ vựng (Lexicon)**.

- **Lớp mở (Open classes):** Danh từ, Động từ, Tính từ, Trạng từ.
(Luôn có từ mới được thêm vào, ví dụ: *selfie*, *google*).
- **Lớp đóng (Closed classes):** Đại từ, Mạo từ, Giới từ, Liên từ. (Số lượng cố định, hiếm khi thay đổi).

<i>Noun</i>	→	stench [0.05] breeze [0.10] wumpus [0.15] pits [0.05] ...
<i>Verb</i>	→	is [0.10] feel [0.10] smells [0.10] stinks [0.05] ...
<i>Adjective</i>	→	right [0.10] dead [0.05] smelly [0.02] breezy [0.02] ...
<i>Adverb</i>	→	here [0.05] ahead [0.05] nearby [0.02] ...
<i>Pronoun</i>	→	me [0.10] you [0.03] I [0.10] it [0.10] ...
<i>RelPro</i>	→	that [0.40] which [0.15] who [0.20] whom [0.02] ...
<i>Name</i>	→	Ali [0.01] Bo [0.01] Boston [0.01] ...
<i>Article</i>	→	the [0.40] a [0.30] an [0.10] every [0.05] ...
<i>Prep</i>	→	to [0.20] in [0.10] on [0.05] near [0.10] ...
<i>Conj</i>	→	and [0.50] or [0.10] but [0.20] yet [0.02] ...
<i>Digit</i>	→	0 [0.20] 1 [0.20] 2 [0.20] 3 [0.20] 4 [0.20] ...

Figure 3: Ví dụ về Từ vựng cho tập $\mathcal{E}_0$, liệt kê các từ thuộc từng danh mục từ loại tương ứng.

24.3 Phân tích cú pháp (Parsing)

- ◇ **Phân tích cú pháp:** Quá trình suy diễn cấu trúc cú pháp (Cây phân tích) của một câu dựa trên ngữ pháp cho trước.
- ◇ Có thể xem Parsing như một bài toán **Tìm kiếm (Search problem)**. Thuật toán A^* có thể được sử dụng với các hàm Heuristic đánh giá xác suất của các luật sinh.

List of items	Rule
<i>S</i>	
<i>NP VP</i>	$S \rightarrow NP VP$
<i>NP VP Adjective</i>	$VP \rightarrow VP Adjective$
<i>NP Verb Adjective</i>	$VP \rightarrow Verb$
<i>NP Verb dead</i>	$Adjective \rightarrow \mathbf{dead}$
<i>NP is dead</i>	$Verb \rightarrow \mathbf{is}$
<i>Article Noun is dead</i>	$NP \rightarrow Article Noun$
<i>Article wumpus is dead</i>	$Noun \rightarrow \mathbf{wumpus}$
<i>the wumpus is dead</i>	$Article \rightarrow \mathbf{the}$

Figure 4: Phân tích cú pháp chuỗi "The wumpus is dead" dưới dạng một bài toán tìm kiếm từ dưới lên (Bottom-up).

24.3 Thuật toán CYK và Cây Cú pháp

◇ **Thuật toán CYK (Cocke-Younger-Kasami):** Thuật toán quy hoạch động kinh điển dùng để phân tích cú pháp với PCFG. Độ phức tạp $\mathcal{O}(n^3)$.

```

function CYK-PARSE(words, grammar) returns a table of parse trees
  inputs: words, a list of words
           grammar, a structure with LEXICALRULES and GRAMMARRULES
   $T \leftarrow$  a table      //  $T[X, i, k]$  is most probable  $X$  tree spanning  $words_{i:k}$ 
   $P \leftarrow$  a table, initially all 0      //  $P[X, i, k]$  is probability of tree  $T[X, i, k]$ 
  // Insert lexical categories for each word.
  for  $i = 1$  to LEN(words) do
    for each  $(X, p)$  in grammar.LEXICALRULES( $words_i$ ) do
       $P[X, i, i] \leftarrow p$ 
       $T[X, i, i] \leftarrow \text{TREE}(X, words_i)$ 
  // Construct  $X_{i:k}$  from  $Y_{i:j} + Z_{j+1:k}$ , shortest spans first.
  for each  $(i, j, k)$  in SUBSPANS(LEN(words)) do
    for each  $(X, Y, Z, p)$  in grammar.GRAMMARRULES do
       $PYZ \leftarrow P[Y, i, j] \times P[Z, j+1, k] \times p$ 
      if  $PYZ > P[X, i, k]$  do
         $P[X, i, k] \leftarrow PYZ$ 
         $T[X, i, k] \leftarrow \text{TREE}(X, T[Y, i, j], T[Z, j+1, k])$ 
  return  $T$ 

function SUBSPANS( $N$ ) yields  $(i, j, k)$  tuples
  for length = 2 to  $N$  do
    for  $i = 1$  to  $N + 1 - \text{length}$  do
       $k \leftarrow i + \text{length} - 1$ 
      for  $j = i$  to  $k - 1$  do
        yield  $(i, j, k)$ 

```

Figure 5: Mã giả của Thuật toán CYK, tìm ra cây phân tích cú pháp có xác suất cao nhất cho một chuỗi từ đầu vào.




Figure 6: Ví dụ về một Cây phân tích cú pháp (Parse Tree) hoàn chỉnh cho một câu tiếng Anh.

24.3 Phân tích Cú pháp Phụ thuộc

- ◇ **Cú pháp phụ thuộc (Dependency parsing):** Cấu trúc cú pháp được biểu diễn trực tiếp bằng các **quan hệ nhị phân** (mỗi tên phụ thuộc) giữa các từ vựng với nhau, thay vì các thành phần trừu tượng (NP, VP).
- ◇ Rất hiệu quả cho các ngôn ngữ có trật tự từ tự do.




Figure 7: So sánh giữa Cây phân tích phụ thuộc (trên) và Cây phân tích cấu trúc cụm từ truyền thống (dưới).

24.4 Ngữ pháp Tang cường (Augmented Grammars)

◇ Ngữ pháp PCFG cơ bản gặp khó khăn với các hiện tượng phức tạp của ngôn ngữ tự nhiên:

- Sự phù hợp (Agreement): Số ít - Số ít (The dog *barks*), Số nhiều - Số nhiều.
- Dịch chuyển thành phần (Movement): Khi một cụm từ bị tách ra khỏi vị trí gốc của nó trong cây.

[[S [NP-2 **Her eyes**]
 [VP **were**
 [VP **glazed**
 [NP *-2]
 [SBAR-ADV **as if**
 [S [NP **she**]
 [VP **did n't**
 [VP [VP **hear** [NP *-1]]
 or
 [VP [ADV **even**] **see** [NP *-1]]
 [NP-1 **him**]]]]]]]]
 .]

Figure 8: Ví dụ về một cây được chú thích xử lý hiện tượng "di chuyển cụm từ" (movement) bằng cách sử dụng các dấu vết (traces) như *-1.

24.4 Ngữ pháp Tang cường với Biến

◇ Thay vì tạo ra hàng trăm quy tắc con (NP-SốÍt, NP-SốNhiều), ta có thể **Tang cường (Augment)** ngữ pháp bằng cách thêm các **Biến (Variables)**.

- Ví dụ: $NP(c, pn, n)$ với c là cách (chủ ngữ/tân ngữ), pn là ngôi/số, n là danh từ trung tâm.

$$\begin{aligned}
S(v) &\rightarrow NP(Sbj, pn, n) VP(pn, v) \mid \dots \\
NP(c, pn, n) &\rightarrow Pronoun(c, pn, n) \mid Noun(c, pn, n) \mid \dots \\
VP(pn, v) &\rightarrow Verb(pn, v) NP(Obj, pn, n) \mid \dots \\
PP(head) &\rightarrow Prep(head) NP(Obj, pn, h) \\
Pronoun(Sbj, 1S, \mathbf{I}) &\rightarrow \mathbf{I} \\
Pronoun(Sbj, 1P, \mathbf{we}) &\rightarrow \mathbf{we} \\
Pronoun(Obj, 1S, \mathbf{me}) &\rightarrow \mathbf{me} \\
Pronoun(Obj, 3P, \mathbf{them}) &\rightarrow \mathbf{them} \\
Verb(3S, \mathbf{see}) &\rightarrow \mathbf{see}
\end{aligned}$$

Figure 9: Một phần của ngữ pháp tăng cường xử lý tính phù hợp về cách (case agreement) và từ trung tâm.

24.4 Diễn giải Ngữ nghĩa (Semantic Interpretation)

- ◇ Mục tiêu cuối cùng của NLP không chỉ là cấu trúc, mà là **Ý nghĩa (Semantics)**. Ta phải gán ngữ nghĩa cho từng cụm từ.
- ◇ **Nguyên lý ngữ nghĩa hợp thành (Compositional semantics)**: Ý nghĩa của một cụm từ là hàm của ý nghĩa các phần cấu thành nên nó.

$$\begin{aligned}
&Exp(op(x_1, x_2)) \rightarrow Exp(x_1) Operator(op) Exp(x_2) \\
&Exp(x) \rightarrow (Exp(x)) \\
&Exp(x) \rightarrow Number(x) \\
&Number(x) \rightarrow Digit(x) \\
&Number(10 \times x_1 + x_2) \rightarrow Number(x_1) Digit(x_2) \\
&Operator(+) \rightarrow + \\
&Operator(-) \rightarrow - \\
&Operator(\times) \rightarrow \times \\
&Operator(\div) \rightarrow \div \\
&Digit(0) \rightarrow \mathbf{0} \\
&Digit(1) \rightarrow \mathbf{1} \\
&\dots
\end{aligned}$$

Figure 10: Một ngữ pháp tính toán số học được tăng cường với ngữ nghĩa (Mỗi quy tắc chứa cách tính giá trị biểu thức).

Figure 11: Cây phân tích cú pháp kèm diễn giải ngữ nghĩa cho chuỗi $3 + (4 / 2)$.

24.4 Diễn giải Ngữ nghĩa trong Ngôn ngữ tự nhiên

◇ Với ngôn ngữ tự nhiên, ngữ nghĩa phức tạp hơn nhiều phép toán học. Chúng ta sử dụng Logic bậc nhất (First-Order Logic - FOL) và Hàm Lambda λ để biểu diễn.

- Động từ "loves" được biểu diễn thành $\lambda y \lambda x \text{ Loves}(x, y)$.

$S(pred(n)) \rightarrow NP(n) VP(pred)$
 $VP(pred(n)) \rightarrow Verb(pred) NP(n)$
 $NP(n) \rightarrow Name(n)$

 $Name(Ali) \rightarrow \mathbf{Ali}$
 $Name(Bo) \rightarrow \mathbf{Bo}$
 $Verb(\lambda y \lambda x \text{ Loves}(x, y)) \rightarrow \mathbf{loves}$




Figure 12: Một ngữ pháp đơn giản có khả năng dẫn xuất ra cả Cây phân tích cú pháp lẫn Ý nghĩa logic (Semantics) của một câu.

Tóm tắt Chương 24

- ◇ **Mô hình Ngôn ngữ:** N-gram và Mô hình túi từ (Bag-of-words) cung cấp xác suất của các từ dựa trên ngữ cảnh ngắn hạn.
- ◇ **Ngữ pháp (Grammar):** Ngữ pháp phi ngữ cảnh xác suất (PCFG) quy định các quy tắc cấu trúc của một câu.
- ◇ **Phân tích cú pháp (Parsing):** Thuật toán CYK, A* Search và Cú pháp Phụ thuộc giúp trích xuất cấu trúc cây từ chuỗi văn bản.
- ◇ **Ngữ pháp Tang cường:** Thêm các tham số và logic lambda để xử lý sự phù hợp (Agreement) và sinh ra Ý nghĩa ngữ nghĩa tự động từ cây cú pháp.