

CHƯƠNG 25: HỌC SÂU CHO XỬ LÝ NGÔN NGỮ TỰ NHIÊN (DEEP LEARNING FOR NLP)

TRÍ TUỆ NHÂN TẠO - ARTIFICIAL INTELLIGENCE

Nội dung Chương 25

- ◇ 25.1 Nhúng từ (Word Embeddings)
- ◇ 25.2 Mạng nơ-ron hồi quy (RNN) cho NLP
- ◇ 25.3 Mô hình Chuỗi sang Chuỗi (Sequence-to-Sequence)
- ◇ 25.4 Kiến trúc Transformer (The Transformer)
- ◇ 25.5 Tiền huấn luyện và Học chuyển giao (Pretraining & Transfer Learning)
- ◇ 25.6 Trạng thái kỹ thuật hiện tại (State of the Art)

25.1 Nhúng từ (Word Embeddings)

◇ **Biểu diễn từ:** Trong NLP truyền thống, từ được biểu diễn bằng vectơ one-hot (rất thưa và không mang ngữ nghĩa). Học sâu sử dụng **Nhúng từ (Word Embeddings)** - các vectơ dày đặc liên tục (vd: 300 chiều).

◇ **Đặc điểm:** Các từ có ngữ nghĩa tương đồng (quốc gia, màu sắc, thức ăn) sẽ nằm gần nhau trong không gian vectơ nhúng này.




Figure 1: Không gian vectơ nhúng từ cho thấy sự phân cụm rõ rệt theo chủ đề: Quốc gia, Quan hệ gia đình, Thức ăn.

25.1 Các tính chất của Nhúng từ

◇ **Toán học của ngữ nghĩa:** Khả năng học được mối quan hệ logic thông qua các phép trừ/cộng vectơ.

- $V(\text{Oslo}) \approx V(\text{Athens}) - V(\text{Greece}) + V(\text{Norway})$
- $V(\text{King}) \approx V(\text{Man}) - V(\text{Woman}) + V(\text{Queen})$

A	B	C	D = C + (B - A)	Relationship
Athens	Greece	Oslo	Norway	<i>Capital</i>
Astana	Kazakhstan	Harare	Zimbabwe	<i>Capital</i>
Angola	kwanza	Iran	rial	<i>Currency</i>
copper	Cu	gold	Au	<i>Atomic Symbol</i>
Microsoft	Windows	Google	Android	<i>Operating System</i>
New York	New York Times	Baltimore	Baltimore Sun	<i>Newspaper</i>
Berlusconi	Silvio	Obama	Barack	<i>First name</i>
Switzerland	Swiss	Cambodia	Cambodian	<i>Nationality</i>
Einstein	scientist	Picasso	painter	<i>Occupation</i>
brother	sister	grandson	granddaughter	<i>Family Relation</i>
Chicago	Illinois	Stockton	California	<i>State</i>
possibly	impossibly	ethical	unethical	<i>Negative</i>
mouse	mice	dollar	dollars	<i>Plural</i>
easy	easiest	lucky	luckiest	<i>Superlative</i>
walking	walked	swimming	swam	<i>Past tense</i>

Figure 2: Toán học vectơ cho thấy biểu diễn hình học của mối quan hệ tương đồng giữa các từ vựng.

25.2 Gán nhãn Từ loại bằng Mạng Nơ-ron

◇ Mạng nơ-ron truyền thẳng (Feed-forward NN) có thể dùng để gán nhãn từ loại (POS Tagging) bằng cách xem xét cửa sổ (window) các từ xung quanh.




Figure 3: Cấu trúc mạng nơ-ron truyền thẳng xuất ra nhãn từ loại từ một cửa sổ vắn bản, kết hợp ma trận nhúng từ.

25.2 Mạng Nơ-ron Hồi quy (RNN) cho NLP

◇ **RNN (Recurrent Neural Networks):** Có cấu trúc hồi quy, cho phép duy trì **Trạng thái ẩn (Hidden state)** để ghi nhớ ngữ cảnh từ quá khứ, giải quyết vấn đề đầu vào có độ dài biến đổi của ngôn ngữ tự nhiên.




Figure 4: Sơ đồ RNN với vòng lặp (trái) và sau khi trải ra theo thời gian (phải) để dự đoán hoặc phân loại.

25.2 RNN trong Mô hình Ngôn ngữ

◇ RNN đặc biệt mạnh mẽ khi làm **Mô hình Ngôn ngữ (Language Models)**, dự đoán từ tiếp theo dựa trên toàn bộ chuỗi từ phía trước, thay vì chỉ giới hạn trong một N-gram cố định.




Figure 5: Mô hình dự đoán từ tiếp theo sử dụng RNN. Biểu diễn ngữ cảnh phụ thuộc vào đầu vào hiện tại và trạng thái ẩn trước đó.

25.3 Mô hình Chuỗi sang Chuỗi (Seq2Seq)

◇ **Seq2Seq**: Kiến trúc nền tảng cho **Dịch máy (Machine Translation)**.

- **Bộ mã hóa (Encoder)**: Đọc toàn bộ câu nguồn và nén thành một vectơ ngữ cảnh (Context vector) duy nhất.
- **Bộ giải mã (Decoder)**: Nhận vectơ ngữ cảnh và sinh ra từng từ của câu đích.




Figure 6: Cấu trúc Seq2Seq cơ bản với LSTM dịch từ "The man is tall" sang ngôn ngữ đích.

25.3 Cơ chế Chú ý (Attention)

◇ Vấn đề của Seq2Seq cơ bản là vector ngữ cảnh duy nhất trở thành nút thắt cổ chai (bottleneck) với câu quá dài. ◇ **Cơ chế Chú ý**

(Attention): Cho phép Decoder "nhìn" lại toàn bộ các trạng thái ẩn của Encoder và tự quyết định phần nào của câu nguồn là quan trọng nhất đối với từ đang dịch.




Figure 7: Cơ chế chú ý giúp mô hình tập trung linh hoạt vào các phần khác nhau của câu nguồn qua hàm xác suất Softmax.

25.3 Tìm kiếm Chùm tia (Beam Search)

- ◇ Khi giải mã (Decoding) tạo ra câu mới, nếu chỉ chọn từ có xác suất cao nhất (Greedy) sẽ dễ dẫn đến câu tối ưu cục bộ kém chất lượng.
- ◇ **Beam Search:** Giữ lại b chuỗi giả thuyết tốt nhất (kích thước chùm tia) tại mỗi bước, giúp tìm ra câu dịch hoàn thiện và tự nhiên hơn.




Figure 8: Thuật toán Tìm kiếm chùm tia với kích thước $b = 2$, mở rộng và đánh giá các lựa chọn tốt nhất.

25.4 Kiến trúc Transformer

◇ Bài báo "Attention Is All You Need" (2017) đã thay đổi hoàn toàn NLP: **Loại bỏ hoàn toàn RNN/CNN**, chỉ sử dụng **Tự chú ý (Self-Attention)**. ◇ Tự chú ý cho phép mỗi từ trong câu "chú ý" tới mọi từ khác trong cùng một câu để hiểu rõ ngữ cảnh mà không phụ thuộc vào trình tự tuần tự (tính toán song song cực nhanh).




Figure 9: Mô đun Tự chú ý (Self-Attention) cốt lõi bên trong lớp Transformer.

25.4 Transformer cho các Tác vụ NLP

◇ Transformer có thể thay thế RNN để thực hiện các tác vụ như POS Tagging. Nó kết hợp biểu diễn từ (word embeddings) và biểu diễn vị trí (positional embeddings) để nắm bắt cấu trúc câu.




Figure 10: Sử dụng kiến trúc Transformer để thực hiện Gán nhãn Từ loại (POS Tagging).

25.5 Tiền Huấn Luyện (Pretraining) & Ngữ cảnh

◇ Các từ giống nhau nhưng có nghĩa khác nhau (ví dụ: *bank* - ngân hàng / bờ sông). ◇ **Nhúng từ theo ngữ cảnh (Contextual Embeddings):** Tạo ra các vectơ nhúng động, phụ thuộc vào toàn bộ câu thay vì cố định trong từ điển.




Figure 11: Mạng nơ-ron tạo ra nhúng từ có ngữ cảnh, giúp phân biệt ý nghĩa của từ dựa vào các từ xung quanh.

25.5 Các Mô hình Ngôn ngữ Bị che (MLM)

◇ **Mô hình Ngôn ngữ bị che (Masked Language Modeling - MLM):** Kỹ thuật được sử dụng bởi **BERT**. Hệ thống cố tình che giấu một số từ trong câu và buộc mô hình phải dự đoán từ đó bằng ngữ cảnh từ cả 2 phía.




Figure 12: Đào tạo mô hình BERT bằng cách che các từ đầu vào và yêu cầu mô hình dự đoán chính xác từ bị che.

25.6 Trạng thái Kỹ thuật Hiện tại (State of the Art)

◇ Ứng dụng Học Sâu (Deep Learning) mang lại các bước nhảy vọt phi thường cho NLP, điển hình là khả năng suy luận, đọc hiểu phức tạp và Trả lời câu hỏi (QA).

200

Chapter 25 Deep Learning for Natural Language Processing

Figure 13: Hệ thống ARISTO vượt qua bài thi Khoa học lớp 8 bằng cách kết hợp Mô hình ngôn ngữ lớn (LLM) và Lập luận định tính.

25.6 Mô hình Ngôn ngữ Sinh tự động (Generative AI)

◇ Các biến thể Transformer cực lớn (như GPT-2, GPT-3, GPT-4) được huấn luyện trên hàng triệu GB văn bản có khả năng tự động sinh văn bản, viết mã nguồn, dịch thuật cực kỳ thuyết phục.

201

It is a truth universally acknowledged that the earth is not the center of the universe. There are those who assert there is. I do not accept them, but others I consider to be of the same opinion. The truth is, however, that if there are other than the center, and if there are any other living things in the universe and if they are not human, then we do not yet have our answers. We have to go on. This page gives a simplified, simplified answer to the problem. We don't have all the answers. The truth is, however, that the truth is out there.

Figure 14: Mô hình GPT-2 sinh ra những đoạn văn bản logic và tự nhiên đến mức khó tin chỉ từ một câu nhắc (prompt) ngắn.

Tóm tắt Chương 25

- ◇ **Nhúng từ (Embeddings):** Biểu diễn ngữ nghĩa của từ thành vectơ toán học.
- ◇ **RNN và Seq2Seq:** Công cụ khởi nguyên mạnh mẽ cho xử lý chuỗi và Dịch máy nơ-ron (Neural Machine Translation).
- ◇ **Cơ chế Chú ý & Transformer:** Cách mạng hóa NLP nhờ khả năng bắt ngữ cảnh song song, triệt tiêu nhược điểm thất cổ chai của RNN.
- ◇ **Tiền Huấn Luyện (Pretraining):** BERT và GPT thiết lập chuẩn mực mới nhờ khả năng học chuyển giao ngữ cảnh khổng lồ từ kho dữ liệu Internet.