

CHƯƠNG 16: RA QUYẾT ĐỊNH PHỨC TẠP

TRÍ TUỆ NHÂN TẠO - ARTIFICIAL INTELLIGENCE

Nội dung Chương 16

- ◇ 16.1 Các Bài toán Quyết định Tuần tự (Sequential Decision Problems)
- ◇ 16.2 Thuật toán cho các MDP (Algorithms for MDPs)
- ◇ 16.3 Các Bài Toán Máy Đánh Bạc (Bandit Problems)
- ◇ 16.4 Các bài toán MDP có thể Quan sát Một phần (POMDP)
- ◇ 16.5 Các thuật toán giải POMDP

16.1 Bài toán Quyết định Tuần tự

◇ Trong các chương trước, tác nhân chỉ cần ra quyết định một lần (one-shot decision).


◇ **Bài toán Quyết định Tuần tự (Sequential Decision Problem):**

- Tác nhân phải đưa ra một *chuỗi* các quyết định.
- Sự lựa chọn ở hiện tại không chỉ đem lại phần thưởng ngay lập tức mà còn làm thay đổi trạng thái môi trường và kết quả của các quyết định trong tương lai.


◇ **Ví dụ:** Chơi cờ, lái xe, hoặc đầu tư tài chính.

Giới thiệu Quá trình Ra quyết định Markov

◇ **Quá trình Ra quyết định Markov (MDP)** mô hình hóa các bài toán ra quyết định tuần tự trong môi trường không chắc chắn. **Mục tiêu:** Tìm một **Chính sách (Policy - π)**.




(a)




(b)

Figure 16.1: (a) Môi trường 4x3 đơn giản. (b) Mô hình chuyển đổi ngẫu nhiên của hành động "Up".


Chính sách Tối ưu trong MDP




(a)




$$r < -1.6497$$



$$-0.7311 < r < -0.4526$$



$$-0.0274 < r < 0$$



$$r > 0$$

(b)

Figure 16.2: Các chính sách tối ưu tùy thuộc vào mức độ rủi ro (chi phí của mỗi bước đi).

16.1 Định nghĩa cấu trúc của một MDP

◇ Một MDP được định nghĩa chính thức bởi cụm 4 thành tố (S, A, P, R) :

1. S (**States**): Tập hợp tất cả các trạng thái có thể có của môi trường.
2. A (**Actions**): Tập hợp các hành động mà tác nhân có thể thực hiện.
3. $P(s'|s, a)$ (**Transition Model**): Xác suất chuyển từ trạng thái s sang trạng thái s' nếu thực hiện hành động a .
4. $R(s)$ (**Reward Function**): Phần thưởng thu được khi đạt tới trạng thái s (có thể âm nếu là hình phạt).

Mạng Quyết Định Động (Dynamic Decision Network)






Figure 16.3: Mạng quyết định động cho một rô-bốt di động (với các biến trạng thái và hành động).

Mô Hình Hóa Một Trò Chơi Phức Tạp: Tetris



(a)



(b)

Figure 16.4: (a) Trò chơi xếp hình Tetris. (b) Mạng DDN tương ứng cho Tetris.

Hữu dụng theo thời gian & Hệ số chiết khấu

◇ **Hệ số chiết khấu (Discount factor - γ):** Hằng số $0 \leq \gamma < 1$ giảm giá trị phần thưởng tương lai để tổng hữu dụng hội tụ:

$$U = \sum_{t=0}^{\infty} \gamma^t R(s_t).$$

16.2 Hữu dụng của Trạng thái và Phương trình Bellman

◇ $U(s)$ bao gồm phần thưởng tại s cộng với kỳ vọng tổng phần thưởng tương lai. **Phương trình Bellman** thể hiện mối liên hệ này.

3	0.8516	0.9078	0.9578	+1
2	0.8016		0.7003	-1
1	0.7453	0.6953	0.6514	0.4279
	1	2	3	4

16.2 Chi tiết Phương trình Bellman

◇ Phương trình Bellman:

- $U(s) = R(s) + \gamma \max_{a \in A} \sum_{s'} P(s'|s, a) U(s')$

◇ Ý nghĩa:

- $R(s)$: Lợi ích ngay lập tức.
- $\max_a$: Tác nhân chọn hành động tốt nhất.
- $\sum_{s'} P(s'|s, a) U(s')$: Tính kỳ vọng lợi ích tương lai tại các trạng thái tiếp theo s' , phụ thuộc vào xác suất chuyển đổi.

◇ Nếu có n trạng thái, ta sẽ có hệ n phương trình phi tuyến tính (vì có phép max).

Thuật toán Lặp Giá trị (Value Iteration)

function VALUE-ITERATION(mdp, ϵ) **returns** a utility function
 inputs: mdp , an MDP with states S , actions $A(s)$, transition model $P(s' | s, a)$,
 rewards $R(s, a, s')$, discount γ
 ϵ , the maximum error allowed in the utility of any state
 local variables: U, U' , vectors of utilities for states in S , initially zero
 δ , the maximum relative change in the utility of any state

 repeat
 $U \leftarrow U'; \delta \leftarrow 0$
 for each state s **in** S **do**
 $U'[s] \leftarrow \max_{a \in A(s)} \text{Q-VALUE}(mdp, s, a, U)$
 if $|U'[s] - U[s]| > \delta$ **then** $\delta \leftarrow |U'[s] - U[s]|$
 until $\delta \leq \epsilon(1 - \gamma)/\gamma$
 return U

Figure 16.6: Mã giả thuật toán Value Iteration để giải phương trình Bellman.

Sự hội tụ của Lặp Giá trị




Figure 16.7: (a) Quá trình tiến tới hội tụ của các giá trị $U(s)$. (b) Số vòng lặp cần thiết.

Đánh giá Sai số trong Lặp Giá trị




Figure 16.8: Sự sụt giảm sai số tối đa (Max error) và tổn thất chính sách (Policy loss).

Thuật toán Lặp Chính sách (Policy Iteration)

```
function POLICY-ITERATION(mdp) returns a policy
  inputs: mdp, an MDP with states  $S$ , actions  $A(s)$ , transition model  $P(s' | s, a)$ 
  local variables:  $U$ , a vector of utilities for states in  $S$ , initially zero
                   $\pi$ , a policy vector indexed by state, initially random

  repeat
     $U \leftarrow \text{POLICY-EVALUATION}(\pi, U, mdp)$ 
    unchanged?  $\leftarrow$  true
    for each state  $s$  in  $S$  do
       $a^* \leftarrow \underset{a \in A(s)}{\text{argmax}} \text{Q-VALUE}(mdp, s, a, U)$ 
      if  $\text{Q-VALUE}(mdp, s, a^*, U) > \text{Q-VALUE}(mdp, s, \pi[s], U)$  then
         $\pi[s] \leftarrow a^*$ ; unchanged?  $\leftarrow$  false
  until unchanged?
  return  $\pi$ 
```

Figure 16.9: Mã giả thuật toán Policy Iteration: Đánh giá chính sách và Cải tiến chính sách.

Giải pháp Lập kế hoạch Trực tuyến




Figure 16.10: Cây Expectimax cho tìm kiếm trực tuyến trong môi trường MDP.

Hiệu suất của Giải thuật UCT




Figure 16.11: So sánh hiệu năng của giải thuật UCT so với lập giá trị truyền thống.

16.3 Các Bài Toán Máy Đánh Bạc (Bandit Problems)

- ◇ Một lớp đặc biệt của bài toán ra quyết định: Tác nhân đứng trước nhiều máy đánh bạc (Multi-armed bandits), mỗi máy có một xác suất trả thưởng vô danh khác nhau.
- ◇ Tác nhân phải ra quyết định chọn kéo cần gạt nào ở mỗi bước thời gian.
- ◇ **Sự cân bằng cốt lõi:** Khám phá (Exploration) vs. Khai thác (Exploitation).

Mô hình Máy Đánh Bạc (Bandit Problems)




Figure 16.12 (a) A simple deterministic bandit problem with two arms. The arms can be pulled in any order, and each yields the sequence of rewards shown. (b) A more general case of the bandit in (a), where the first arm gives an arbitrary sequence of rewards and the second arm gives a fixed reward λ .

Figure 16.12: Mô hình bài toán máy đánh bạc đơn giản (Deterministic Bandit).

Ví dụ Về Chuỗi Phần Thưởng Bandit




Figure 16.13: Các máy đánh bạc mang lại chuỗi phần thưởng tiềm năng cần được cân nhắc.

Chỉ số Gittins (Gittins Index)





Figure 16.14: Trạng thái niềm tin và sự thay đổi của Chỉ số Gittins theo thời gian.

16.4 Bài toán có thể Quan sát Một phần (POMDP)

◇ **Hạn chế của MDP:** MDP giả định tác nhân luôn biết chính xác nó đang ở trạng thái s nào. Trong thực tế, cảm biến thường bị nhiễu hoặc điểm mù.

◇ **POMDP (Partially Observable Markov Decision Process):** Quá trình ra quyết định Markov quan sát một phần.

- Thêm vào mô hình cảm biến (Observation model): $O(o|s, a)$ - Xác suất nhận được quan sát o khi đang ở trạng thái s sau hành động a .

16.4 Trạng thái Niềm tin trong POMDP

◇ Vì tác nhân không biết s , nó phải duy trì một **Trạng thái Niềm tin (Belief State - b)**.

- $b(s)$ là xác suất mà tác nhân tin rằng nó đang ở trạng thái s .

◇ Sau mỗi hành động a và quan sát o , trạng thái niềm tin được cập nhật theo định lý Bayes:

- $b'(s') = \alpha O(o|s', a) \sum_s P(s'|s, a) b(s)$
- α là hằng số chuẩn hóa.

◇ Một POMDP thực chất là một MDP mà ở đó không gian trạng thái chính là không gian liên tục của các Belief States.

16.5 Các thuật toán giải POMDP

- ◇ Mọi thuật toán của MDP (như Lập giá trị) đều có thể áp dụng cho POMDP trên lý thuyết.
- ◇ Tuy nhiên, không gian trạng thái của MDP là hữu hạn (ví dụ: N trạng thái), trong khi không gian trạng thái niềm tin của POMDP là liên tục đa chiều (một điểm trong đơn hình $(N - 1)$ chiều).
- ◇ **Biểu diễn Hữu dụng POMDP:** Hàm $U(b)$ có dạng tuyến tính từng phần và lồi (Piecewise-linear and convex).

16.5 Các thuật toán giải POMDP (Tiếp theo)




Figure 16.15: Hàm hữu dụng $U(b)$ là sự kết hợp của các kế hoạch không bị thống trị.

Lập Giá Trị Cho POMDP

function POMDP-VALUE-ITERATION(*pomdp*, ϵ) **returns** a utility function
inputs: *pomdp*, a POMDP with states S , actions $A(s)$, transition model $P(s' | s, a)$,
sensor model $P(e | s)$, rewards $R(s, a, s')$, discount γ
 ϵ , the maximum error allowed in the utility of any state
local variables: U , U' , sets of plans p with associated utility vectors α_p
 $U' \leftarrow$ a set containing all one-step plans $[a]$, with $\alpha_{[a]}(s) = \sum_{s'} P(s' | s, a) R(s, a, s')$
repeat
 $U \leftarrow U'$
 $U' \leftarrow$ the set of all plans consisting of an action and, for each possible next percept,
 a plan in U with utility vectors computed according to Equation (16.18)
 $U' \leftarrow \text{REMOVE-DOMINATED-PLANS}(U')$
until MAX-DIFFERENCE(U, U') $\leq \epsilon(1 - \gamma)/\gamma$
return U

Figure 16.16: Thuật toán POMDP-VALUE-ITERATION giải quyết không gian trạng thái niềm tin liên tục.

16.5 Sự bùng nổ không gian trong POMDP

◇ Mặc dù có các thuật toán giải chính xác POMDP, nhưng độ phức tạp tính toán cực kỳ khủng khiếp:

- Giải POMDP chính xác thuộc lớp PSPACE-hard.
- Số lượng siêu phẳng đại diện cho hàm Hữu dụng có thể tăng theo hàm mũ kép sau mỗi lần lặp.

Tìm kiếm Trục tuyến trong POMDP




Figure 16.17: Cây tìm kiếm Expectimax đối với Không gian Trạng thái niềm tin của POMDP.

Hành động thực tế và Niềm tin




Figure 16.18: Chuỗi cập nhật nhận thức, trạng thái niềm tin và hành động theo thời gian.

Tóm tắt Chương 16

- ◇ **MDP (Markov Decision Process)** cung cấp nền tảng chuẩn xác cho các bài toán ra quyết định chuỗi thời gian, nơi hành động hiện tại ảnh hưởng đến tương lai.
- ◇ **Phương trình Bellman** là cốt lõi để giải quyết MDP thông qua các thuật toán *Lập giá trị* và *Lập chính sách*.
- ◇ **Bài toán Bandit** định hình lại triết lý tối ưu giữa Khám phá cái mới và Khai thác cái tốt nhất hiện tại.
- ◇ **POMDP** phản ánh thực tế khắc nghiệt nhất: Môi trường vừa ngẫu nhiên, vừa bị che khuất. Trạng thái niềm tin (Belief State) là công cụ duy nhất để duy trì lý trí.