

CHƯƠNG 21: HỌC CÁC MÔ HÌNH XÁC SUẤT

TRÍ TUỆ NHÂN TẠO - ARTIFICIAL INTELLIGENCE

Nội dung Chương 21

- ◇ 21.1 Học máy Thống kê (Statistical Learning)
- ◇ 21.2 Học với Dữ liệu Đầy đủ (Learning with Complete Data)
- ◇ 21.3 Học với các Biến ẩn: Thuật toán EM (Learning with Hidden Variables)

21.1 Học máy Thống kê

- ◇ Khác với lập trình logic chỉ quan tâm đến Đúng (True) hay Sai (False) một cách tuyệt đối, **Học máy thống kê (Statistical Learning)** tiếp cận thế giới dưới góc độ Xác suất.
- ◇ Dữ liệu (Data) là một chuỗi các sự kiện quan sát được.
- ◇ **Mục tiêu:** Xây dựng một mô hình toán học (được đặc trưng bởi các tham số θ) để giải thích sự sinh ra của dữ liệu này.
- ◇ **Hai bài toán chính:**
 - Học cấu trúc (Structure Learning): Tìm mối liên kết giữa các biến.
 - Học tham số (Parameter Learning): Điền các con số cụ thể vào bảng xác suất.

21.2 Học với Dữ liệu Đầy đủ

◇ ****Dữ liệu đầy đủ (Complete Data):**** Mọi điểm dữ liệu trong tập huấn luyện đều có đầy đủ giá trị cho mọi biến, không bị khuyết thiếu (Missing).

◇ **Học tham số Hợp lý cực đại (Maximum Likelihood Estimation - MLE):**

- Là phương pháp thống kê kinh điển nhất.
- **Nguyên lý:** Tham số tốt nhất θ là tham số làm cho Xác suất sinh ra bộ dữ liệu hiện tại là CAO NHẤT.
- $\theta_{MLE} = \operatorname{argmax}_{\theta} P(\text{data}|\theta)$

21.2 Học với Dữ liệu Đầy đủ (Tiếp theo)




Figure 21.1: Mô phỏng sự hội tụ của dự đoán Bayes về giả thuyết thực sự khi lượng dữ liệu tăng dần.

21.2 Cực đại hóa Khả năng Log (Log-Likelihood)

- ◇ Xác suất của toàn bộ tập dữ liệu (với các điểm độc lập) là tích của các xác suất nhỏ: $P(\text{data}|\theta) = \prod_j P(x_j|\theta)$
- ◇ **Vấn đề:** Tích của nhiều số nhỏ sẽ gây tràn bộ nhớ (Underflow), và đạo hàm một tích rất phức tạp.
- ◇ **Giải pháp - Log-Likelihood:**
 - Lấy logarit hai vế để biến Tích thành Tổng.
 - $L(\theta) = \sum_j \log P(x_j|\theta)$
 - Sau đó, ta tính đạo hàm riêng $\frac{\partial L}{\partial \theta}$, đặt bằng 0 để tìm θ_{MLE} .

21.2 Mô hình Sinh vs. Phân biệt

◇ Mô hình Sinh (Generative models):

- Mô hình hóa quá trình tạo ra dữ liệu. Tính toán $P(X, Y)$.
- Naive Bayes, Hidden Markov Models.
- Học nhanh hơn nhưng cần nhiều dữ liệu để đạt đỉnh.

◇ Mô hình Phân biệt (Discriminative models):

- Học trực tiếp cách vẽ đường ranh giới phân loại. Khởi tạo trực tiếp $P(Y|X)$.
- Logistic Regression, SVM, Deep Neural Networks.
- Thường dự đoán chính xác hơn mô hình sinh khi tập dữ liệu đủ lớn.

21.2 Mô hình Sinh vs. Phân biệt (Tiếp theo)




Figure 21.2: Phân biệt giữa mô hình Sinh (Generative models) và mô hình Phân biệt (Discriminative models).

21.2 Học tham số Bayes

◇ **Hạn chế của MLE:** Khi dữ liệu quá nhỏ, MLE rất cực đoan.
(Tung đồng xu 3 lần ra ngửa $\Rightarrow$ MLE dự đoán đồng xu này KHÔNG BAO GIỜ ra sấp).

◇ **Học tham số Bayes (Bayesian Parameter Learning):**

- Khắc phục hiện tượng quá cực đoan bằng cách đưa **Tri thức tiên nghiệm (Prior Knowledge)** vào trước khi quan sát dữ liệu.
- Áp dụng Định lý Bayes:
- $P(\theta|\text{data}) = \alpha P(\text{data}|\theta)P(\theta)$

21.2 Ứng dụng của Học tham số Bayes

◇ Trong ví dụ đồng xu, trước khi tung, ta cho rằng $P(\theta) \approx 0.5$ (Niềm tin ban đầu - Beta distribution).

◇ Khi có dữ liệu mới, niềm tin này sẽ dịch chuyển dần (Posterior distribution).

◇ **Maximum A Posteriori (MAP):**

- Chọn tham số θ để tối đa hóa $P(\theta|\text{data})$.
- MAP chính là MLE được làm mềm (smoothed) bằng một hình thức chuẩn hóa (Regularization).
- Khi dữ liệu tiến tới vô cùng, sức nặng của Prior giảm dần, MAP sẽ bằng MLE.

21.2 Ứng dụng của Học tham số Bayes (Tiếp theo)




Figure 21.3: Sự thay đổi của phân phối Beta (Tri thức tiên nghiệm) khi được cập nhật bằng dữ liệu mới.

21.3 Học với Biến ẩn: Dữ liệu bị thiếu

◇ Trong thế giới thực, dữ liệu hiếm khi "Đầy đủ":

- Bệnh án bị thiếu một vài xét nghiệm máu.
- Có những biến **Không thể quan sát được (Hidden/Latent Variables)** như "Tâm trạng", "Kỹ năng ẩn", "Bệnh lý nền".

21.3 Học với Biến ẩn: Dữ liệu bị thiếu (Tiếp theo)




Figure 21.4: Ảnh hưởng của Biến ẩn (Hidden Variables) làm phức tạp mô hình học máy.

21.3 Tại sao cần Thuật toán EM?

- ◇ Nếu ta biết giá trị của biến ẩn, ta có thể dùng MLE để tính tham số.
- ◇ Ngược lại, nếu ta biết tham số, ta có thể tính ra xác suất của các biến ẩn.
- ◇ **Sự bế tắc (Chicken-and-egg problem):** Ta không biết cả hai! Không có tham số, cũng không có giá trị biến ẩn.
- ◇ Giải pháp vĩ đại của Thống kê học: **Thuật toán Cực đại hóa Kỳ vọng (Expectation-Maximization - EM).**

21.3 Nguyên lý của Thuật toán EM

◇ ****Thuật toán EM**** là một quá trình lặp (Iterative process) khởi tạo tham số ngẫu nhiên rồi từ từ cải thiện chúng.

◇ **Hai bước cốt lõi:**

1. **Bước E (Expectation):** Giữ nguyên tham số θ hiện tại, tính toán giá trị *Kỳ vọng (Xác suất)* cho tất cả các biến bị thiếu trong tập dữ liệu.
2. **Bước M (Maximization):** Coi các giá trị kỳ vọng vừa tính được như là Dữ liệu thật (Hoàn chỉnh dữ liệu). Chạy lại MLE trên dữ liệu mới này để tìm ra bộ tham số θ_{new} tốt hơn.

◇ Lặp đi lặp lại E và M cho đến khi tham số không đổi (Hội tụ cục bộ).

21.3 Hỗn hợp Gaussian (Mixtures of Gaussians)

◇ Một ứng dụng tuyệt vời của EM là **Gom cụm dữ liệu (Clustering)**.

◇ **Mô hình Hỗn hợp Gaussian (GMM):**

- Giả sử dữ liệu được sinh ra từ k quần thể Gaussian khác nhau chồng lấp lên nhau.
- Không có nhãn (Unsupervised). Ta không biết điểm nào thuộc cụm nào.
- Khởi tạo k phân phối ngẫu nhiên.

21.3 Hỗn hợp Gaussian (Mixtures of Gaussians) (Tiếp theo)




Figure 21.5: Gom cụm dữ liệu (Clustering) giả định rằng dữ liệu được sinh ra từ các phân phối xác suất lồng ghép.

21.3 Gom cụm mềm bằng EM

◇ **Khác với k-Means (Gom cụm cứng):** Thuật toán EM trên GMM cung cấp **Gom cụm mềm (Soft Clustering)**.

- Một điểm dữ liệu không thuộc về duy nhất cụm 1 hay cụm 2.
- Nó có xác suất (VD: 80% thuộc cụm 1, 20% thuộc cụm 2).

◇ Quá trình EM sẽ trượt các đường cong Gaussian, kéo giãn ma trận hiệp phương sai cho đến khi chúng ôm trọn các đám mây dữ liệu một cách tinh tế nhất.

21.3 Học tham số cho Mạng Bayes với biến ẩn

- ◇ Thuật toán EM cũng là chìa khóa để học bảng xác suất (CPT) trong Mạng Bayes khi có các Nút ẩn.
- ◇ Ví dụ: Bài toán đoán xem túi kẹo (Cherry, Lime) đang đến từ nhà sản xuất nào, nếu vỏ bọc kẹo (Wrapper) bị giấu (Biến ẩn).

21.3 Học tham số cho Mạng Bayes với biến ẩn (Tiếp theo)




Figure 21.6: Mạng Bayes bao gồm Nút ẩn làm phức tạp đáng kể quá trình học tham số xác suất.

21.3 Ứng dụng EM trong Mô hình Markov ẩn (HMM)

◇ HMM là nền tảng của nhận dạng giọng nói và sinh học tính toán (phân tích DNA).

- Các trạng thái thực sự của hệ thống (Ví dụ: Từ ngữ được nói ra) bị giấu kín.
- Chỉ có tín hiệu âm thanh là quan sát được.

◇ **Thuật toán Baum-Welch:**

- Chính là một trường hợp đặc biệt của thuật toán EM dành riêng cho HMM.
- Bước E: Tính xác suất phân bố của các chuỗi trạng thái ẩn.
- Bước M: Cập nhật lại Ma trận chuyển đổi và Ma trận cảm biến.

Tóm tắt Chương 21

- ◇ **Maximum Likelihood Estimation (MLE):** Công cụ hùng mạnh để học tham số từ dữ liệu, thông qua việc đạo hàm hàm Log-Likelihood.
- ◇ **Học Tham số Bayes & MAP:** Lời giải thông minh để tránh việc mô hình quá tự tin vào một tập dữ liệu nhỏ nhờ Tri thức tiên nghiệm.
- ◇ **Thuật toán EM (Expectation-Maximization):** Siêu thuật toán của học máy, chuyên trị các bài toán không có nhãn hoặc bị khuyết thiếu dữ liệu. Ứng dụng rộng rãi trong GMM, Mạng Bayes và HMM.