

CHƯƠNG 28: TRIẾT HỌC, ĐẠO ĐỨC VÀ AN TOÀN CỦA AI

TRÍ TUỆ NHÂN TẠO - ARTIFICIAL INTELLIGENCE

Nội dung Chương 28

- ◇ 28.1 Các giới hạn của AI (The Limits of AI)
- ◇ 28.2 Máy móc có thể thực sự suy nghĩ không? (Can Machines Really Think?)
- ◇ 28.3 Đạo đức của AI (The Ethics of AI)
- ◇ 28.3.7 An toàn của AI (AI Safety)

28.1 Các giới hạn của AI

◇ **Giới hạn của AI (The Limits of AI):** Chúng ta xem xét liệu có những rào cản nền tảng nào ngăn cản máy tính đạt tới mức độ trí tuệ của con người hay không.

◇ **Lập luận từ sự không chính thức (The argument from informality):** Lập luận cho rằng hành vi của con người quá phức tạp để có thể bị nắm bắt bởi bất kỳ hệ thống quy tắc (rules) chính thức nào. Tuy nhiên, Machine Learning hiện đại không cần luật lệ rõ ràng mà tự học từ dữ liệu, làm suy yếu lập luận này.

28.1 Các giới hạn của AI (Tiếp theo)

◇ **Lập luận từ sự bất lực (The argument from disability):**

Câu nói "Máy móc sẽ không bao giờ có thể làm X" (ví dụ: sáng tác nhạc, biết yêu, có tính hài hước, nhận thức sắc thái). Lịch sử đã chứng minh AI ngày càng phá vỡ nhiều chữ "X" mà con người từng coi là độc quyền.

◇ **Phản đối về mặt toán học (The mathematical objection):**

Định lý Không đầy đủ của Gödel cho thấy các hệ thống logic có những giới hạn về những gì chúng có thể chứng minh. Tuy nhiên, bộ não con người cũng không hoàn hảo và cũng phải đối mặt với các giới hạn nhận thức tương tự.

28.2 Máy móc có thực sự suy nghĩ?

◇ **Sự suy nghĩ của máy móc:** Liệu một hệ thống AI chỉ đang "mô phỏng" (simulate) trí tuệ, hay nó thực sự "suy nghĩ" (Strong AI vs Weak AI)?

◇ **Căn phòng tiếng Trung (The Chinese room):** Thí nghiệm tư duy của triết gia John Searle. Một người không biết tiếng Trung ngồi trong phòng, sử dụng sổ tay quy tắc để trả lời các câu hỏi tiếng Trung. Người đó "hành xử" như hiểu tiếng Trung nhưng thực chất không hiểu gì. Searle dùng nó để lập luận rằng máy tính chỉ thao tác ký hiệu mà không có nhận thức (understanding).

28.2 Ý thức và Cảm giác chủ quan

◇ **Ý thức (Consciousness):** Máy móc có trải nghiệm chủ quan (qualia) không? Ví dụ, cảm giác "đau đớn" hay trải nghiệm về vẻ đẹp của "màu đỏ".

◇ **Bài toán Khó về ý thức (The Hard Problem of Consciousness):** Tại sao và làm thế nào mà các quá trình vật lý lại sinh ra các trải nghiệm chủ quan? Hiện tại chúng ta chưa có cách nào kiểm chứng được liệu máy móc có ý thức hay không, hoặc thậm chí làm sao để chứng minh một người khác đang có ý thức.

28.3 Đạo đức của AI

◇ Khi AI đi sâu vào đời sống, các vấn đề đạo đức trở nên vô cùng cấp bách.

◇ **Vũ khí tự động gây tử vong (Lethal autonomous weapons):** Việc cho phép AI quyết định sự sống và cái chết trên chiến trường đặt ra rủi ro khủng khiếp về mặt nhân đạo và trách nhiệm pháp lý.

◇ **Giám sát, bảo mật và quyền riêng tư (Privacy):** AI nhận diện khuôn mặt và phân tích dữ liệu khổng lồ có thể tạo ra một xã hội bị giám sát toàn diện (như hệ thống chấm điểm công dân), tước đi sự tự do cá nhân.

28.3 Đạo đức của AI: Sự công bằng và Niềm tin

◇ **Sự công bằng và thiên vị (Fairness and bias):** AI học từ dữ liệu của con người, do đó nó có thể học luôn cả các thành kiến về chủng tộc, giới tính (ví dụ: hệ thống tuyển dụng thiên vị nam giới, hay xét duyệt vay vốn phân biệt chủng tộc).

◇ **Niềm tin và sự minh bạch (Trust and transparency):** Khi Deep Learning ngày càng giống một "hộp đen" (black box), làm sao chúng ta có thể tin tưởng vào các quyết định quan trọng của AI (chẩn đoán y tế, tuyên án hình sự) nếu ta không thể giải thích được lý do đằng sau?

28.3 Đạo đức của AI: Tương lai và Quyền

◇ **Tương lai của công việc (The future of work):** Sự tự động hóa và AI đang đe dọa thay thế hàng triệu việc làm, cả chân tay lẫn trí óc. Các cơ chế xã hội mới (như Thu nhập cơ bản phổ quát - UBI) có thể cần thiết để tránh bất bình đẳng cực đoan.

◇ **Quyền của robot (Robot rights):** Nếu một AI đạt đến mức độ có ý thức hoặc cảm nhận được sự đau đớn, liệu chúng ta có nên trao cho chúng các quyền lợi đạo đức giống như con người hay động vật không?

28.3.7 An toàn của AI (AI Safety)

◇ **Bài toán An toàn AI:** Đảm bảo rằng AI thực hiện đúng những gì chúng ta muốn và không gây ra hậu quả thảm khốc khi nó trở nên thông minh hơn con người.

◇ **Sự liên kết giá trị (Value Alignment):** Khó khăn trong việc chỉ định mục tiêu (hàm phần thưởng). Ví dụ: Vua Midas xin mọi thứ chạm vào đều biến thành vàng, và cuối cùng ông chết đói. AI có thể tối ưu hóa mục tiêu theo những cách cực kỳ nguy hiểm mà ta không lường trước.

◇ **Vấn đề kiểm soát (Control Problem):** Làm sao để nhân loại duy trì quyền kiểm soát đối với một thực thể siêu trí tuệ (Superintelligence) thông minh hơn chúng ta hàng triệu lần?

Tóm tắt Chương 28

- ◇ **Giới hạn của AI:** Có nhiều lập luận triết học phản bác khả năng của AI, nhưng sự phát triển công nghệ liên tục xô đổ các rào cản tưởng chừng như không thể vượt qua.
- ◇ **Bản chất của tư duy:** Thí nghiệm Can phòng tiếng Trung và câu hỏi về ý thức vẫn là những bí ẩn lớn giữa khoa học máy tính và triết học.
- ◇ **Đạo đức và Xã hội:** AI mang đến những rủi ro thực tế về thiên vị, mất quyền riêng tư, vũ khí tự động, và tác động kinh tế tới việc làm.
- ◇ **An toàn AI:** Việc căn chỉnh mục tiêu của AI với giá trị của con người (Value Alignment) và đảm bảo kiểm soát an toàn là thách thức sinh tử cho sự tồn vong của nhân loại trong tương lai.